Universidad Católica de Santiago del Estero
Departamento Académico Rafaela
Cesana, Pedro – Lorenzo, Mateo

Informe Final Trabajo Práctico 3

Carrera: Ingeniería en Informática.
Asignatura: Inteligencia Artificial.
Profesores: Rossanigo, Ariel – Fisanotti, Juan Pedro – Ferrero, Mariano - Francesconi, Federico.
Alumnos: Cesana, Pedro - Lorenzo, Mateo.
Entrega: 22 de Octubre del 2026.

Modelado inicial

A partir de los archivos CSV, decidimos comenzar optimizando el archivo de comportamientos bancarios, buscando tener en una fila el resumen del comportamiento de cada usuario, por lo que nos quedamos con la media del saldo promedio mensual y el máximo de días de atraso de otras deudas.

Luego, cruzamos los archivos de datos, mediante el ID_USUARIO, juntando las solicitudes de préstamo de los usuarios con sus comportamientos bancarios previos; realizamos one-hot encodes para los motivos de los préstamos, para que los modelos puedan usarlos.

Además, eliminamos columnas innecesarias, que consideramos que tenderán a “over fitear” los modelos (ID_Solicitud, ID_Usuario, Fecha_Solicitud). Y por último, definimos los X (variables predictoras) e Y (objetivo) que pasaremos al modelo, siendo:

- Variables predictoras:
  - Monto_Solicitado
  - Tasa_Interes
  - Ingreso_Mensual
  - Motivo (del prestamo)
  - avg_monthly_balance (es el promedio del saldo del usuario obtenido en el archivo de comportamientos bancarios)
  - Max_days_past_due (es el máximo de dias de mora que tuvo el usuario en otras deudas)
- Objetivo: predecir “Estado_Final”

Enfoque lógico

El modelo busca determinar la “confianza” de pago de los préstamos basándose en categorías como el tipo de préstamo, el historial del usuario y el monto solicitado. Con eso, se genera un “repayment_probability” que indica la confianza que tendríamos de que se cancele completamente el préstamo.

La probabilidad de pago la utilizamos para ponderar los pesos en la fórmula del ROI (Return of Investment), por lo que los préstamos que se realicen con poca confianza de retorno tenderán a dar un ROI bajo y por ende no ser elegidos posteriormente.

```
gain = test["Monto_Solicitado"] * test["Tasa_Interes"]
loss = test["Monto_Solicitado"]
test["expected_profit"] = (test["repayment_probability"] * gain) - ((1 -
test["repayment_probability"]) * loss)
test["expected_roi"] = test["expected_profit"] / test["Monto_Solicitado"]
```

Luego de que el modelo realice las predicciones y determine las probabilidades de pago, agregamos una fila con los ROI calculados; eliminamos aquellos préstamos que tengan “expected_profit” < 0 para evitar pérdidas y luego ordenamos decrecientemente por esta métrica financiera.

Finalmente, para ir seleccionando, vamos llevando la suma acumulada de lo prestado en una nueva columna “cumulative_amount” y aprobamos los préstamos hasta llegar a la fila en que se excede el presupuesto inicial; obtenemos los IDs de préstamos y modificamos los datos de test colocando si cada préstamo fue aprobado o no.

Luego, se exporta el archivo .csv y vemos un breve resumen con algunas métricas de control, también tenemos un notebook que usamos para comparar 2 csv y ver si existen diferencias significativas entre entregas.

Modelo de Árboles

Para todas las entregas de árboles, utilizamos modelos random forest, a los que fuimos modificando sus métricas (cantidad de árboles y profundidades máximas). Nuestra entrega “masprobableCobroROI.csv” utiliza 150 árboles y 10 niveles de profundidad, y la definimos luego de experimentar entre varias alternativas y ver que esta daba los mejores resultados.

Modelo de Redes Neuronales

Una vez cruzados los CSV, hicimos one-hot encode a los motivos de los préstamos para que el StandardScaler de Scikit-Learn pueda escalar los datos categóricos.
Para todas las entregas de redes neuronales, fuimos modificando los parámetros de la red (capas, épocas, batch size y DropOut). Nuestra entrega utiliza 2 capas ocultas, la primera de 64 y la segunda de 32 neuronas con una capa de salida de 1 neurona que responde con una posibilidad entre 0 y 1 de aceptar o rechazar, entrenamos 60 épocas, con un batch size de 32 y DropOut de 0,35 en la primer capa oculta y 0,3 en la segunda.

Conclusion

El enfoque tomado respecto al cruce de los archivos y el enfoque de maximizar los retornos de inversión nos ha resultado bien y no decidimos probar otros enfoques, dándonos modelos que poseen buen rendimiento (en cuanto a los resultados públicos por lo menos).

Entre ambas alternativas, los modelos random forest tendieron a dar mejores retornos y decidimos entregar también una solución de redes neuronales, en caso de que los resultados privados de los random forest terminen siendo más bajos de lo esperado.